راهنمای فنی

راهنمای بررسی خزش خزنده‌ها

آیا گوگل کارت‌ویزیت‌ها و بیولینک‌ها را می‌بیند؟ چگونه خودم چک کنم؟

پلتفرم آلوشمال — `alooshomal.ir`

تاریخ: ۲۵ مهر ۱۴۰۵

منبع کد: `docs/SEO-CRAWLER-CHECK.md`

پاسخ کوتاه

بله. همه‌ی کارت‌ویزیت‌ها و بیولینک‌های منتشرشده به‌صورت خودکار در `sitemap.xml` فهرست می‌شوند و محتوای هر صفحه به‌صورت HTML سمت سرور (SSR) در اختیار خزنده قرار می‌گیرد؛ نیازی به اجرای جاوااسکریپت نیست.

پرسش	پاسخ	کجای کد
لیست کامل صفحات قابل‌خزش؟	`sitemap.xml`	`apps/web/app/sitemap.ts` + `apps/api/src/seo/`
اجازه‌ی خزش و مسیرهای ممنوع؟	`robots.txt`	`apps/web/app/robots.ts`
محتوای هر کارت قابل‌خواندن است؟	بله، SSR	صفحات `[slug]/page.tsx`
داده‌ی ساخت‌یافته؟	JSON-LD	صفحات جزئیات
لینک‌های داخلی دایرکتوری؟	لینک واقعی `<a href>`	`Directory*Content.tsx`

چطور خودم هر لحظه چک کنم

همه‌ی دستورها روی دامنه‌ی واقعی قابل اجرا هستند (نیاز به نصب چیزی نیست):

```
# ۱) تعداد کل آدرس‌های قابل‌خزش
curl -s https://alooshomal.ir/sitemap.xml | grep -c '<loc>'

# ۲) فقط کارت‌ویزیت‌ها
curl -s https://alooshomal.ir/sitemap.xml | grep -c 'business-cards/'

# ۳) فقط بیولینک‌ها
curl -s https://alooshomal.ir/sitemap.xml | grep -c 'biolinks/'

# ۴) «محتوای یک کارت با «دید گوگل» (بدون اجرای JS)
curl -A "Mozilla/5.0 (compatible; Googlebot/2.1)" \
  https://alooshomal.ir/business-cards/<slug>

# ۵) مجوز خزش و آدرس نقشه‌ی سایت
curl -s https://alooshomal.ir/robots.txt

# ۶) کد پاسخ یک صفحه برای خزنده (باید 200 باشد)
curl -s -o /dev/null -w '%{http_code}\n' \
  -A "Googlebot" https://alooshomal.ir/business-cards/<slug>
```

نکته: در محیط توسعه، `https://alooshomal.ir` را با `http://localhost:3000` جای‌گزین کن.

فهرست کردن همه‌ی آدرس‌ها به‌صورت متن

```
# همه‌ی کارت‌ویزیت‌ها، یک در هر خط
curl -s https://alooshomal.ir/sitemap.xml \
  | grep -oE '<loc>[^<]+business-cards/[^<]+</loc>' \
  | sed -E 's#</?loc>##g'

# همه‌ی بیولینک‌ها
curl -s https://alooshomal.ir/sitemap.xml \
  | grep -oE '<loc>[^<]+biolinks/[^<]+</loc>' \
  | sed -E 's#</?loc>##g'
```

ابزارهای رسمی گوگل

- **Google Search Console → URL Inspection**: همان HTML خامی که گوگل دیده را نشان می‌دهد.
- **Rich Results Test**: اعتبار JSON-LD و امکان نمایش نتایج غنی.
- **Lighthouse / PageSpeed**: بخش SEO (قابل‌خزش بودن و متادیتا).

آیا کارت/بیولینک جدید خودکار وارد لیست می‌شود؟

> **بله.** مکانیزم کاملاً خودکار است و هیچ لیست دستی‌ای وجود ندارد.

1. `apps/web/app/sitemap.ts` هنگام درخواست، اندپوینت `GET /seo/sitemap` را صدا می‌زند.
2. `apps/api/src/seo/seo.service.ts` با یک کوئری زنده از دیتابیس، ردیف‌های `status = APPROVED` و `isPublished = true` را برمی‌گرداند.
3. پس هر آیتم جدید که منتشر و تأیید شود، در درخواست بعدی حاضر است؛ و هر آیتم غیرفعال/حذف‌شده، خودکار حذف می‌شود.

```
# تست سریع زنده از سمت API
curl -s http://localhost:3001/api/seo/sitemap \
  | python3 -c "import sys,json;print(len(json.load(sys.stdin)['data']),'entries')"
```

نکته‌ی مهم: تأخیر کش

> نقشه‌ی سایت `revalidate = 3600` دارد؛ یعنی تا حداکثر یک ساعت ممکن است نسخه‌ی کش‌شده سرو شود. خزنده‌ی گوگل هم بازدید دوره‌ای خودش را دارد و کارت جدید را در بازدید بعدی ایندکس می‌کند (نه فوری).

سقف تعداد

`MAX_ROWS = 20_000` سقف هر نوع ردیف در هر پاسخ است. با عبور از این عدد باید نقشه‌ی سایت به چند فایل صفحه‌بندی شود (sitemap index).

خروجی واقعی نمونه

برای نمونه، محتوایی که یک خزنده از یک کارت واقعی می‌بیند (نسخه‌ی ساده‌شده):

```
{
  "@context": "https://schema.org",
  "@type": "LocalBusiness",
  "name": "شرکت آریا 2300",
  "telephone": "9689271131",
  "address": { "@type": "PostalAddress",
    "streetAddress": "گرگان، خیابان امام، پلاک 179",
    "addressLocality": "گرگان", "addressCountry": "IR" },
  "employee": { "@type": "Person",
    "name": "پویا کرمانی", "jobTitle": "کارشناس کیفیت غذا" }
}
```

چک‌لیست تغییر مکانیزم سئو

- آیا ردیف‌های غیرمنتشرشده/ردشده از sitemap خارج می‌مانند؟
- آیا صفحات ناموجود همچنان `noindex` می‌خورند؟
- آیا `canonical` و Open Graph به‌روز است؟
- آیا لینک‌های دایرکتوری در HTML سمت سرور باقی مانده‌اند؟
- آیا `History-Agent.md` و نسخه‌ی `apps/web/lib/version.ts` به‌روز شده؟